


Classifying Emotion of Thai-Human Voice by Using Deep Learning

การจำแนกอารมณ์จากเสียงพูดภาษาไทยโดยใช้การเรียนรู้เชิงลึก


CEPP64-01



สารบัญ



ส่วนที่ 1:
ที่มาและความสำคัญของ
ปัญหา



ส่วนที่ 4:
งานวิจัยที่เกี่ยวข้อง




ส่วนที่ 2:
วัตถุประสงค์



ส่วนที่ 5:
ขอบเขตของโครงการ




ส่วนที่ 3:
ทฤษฎีที่เกี่ยวข้อง




ส่วนที่ 6:
การพัฒนาโครงการ



สารบัญ



ส่วนที่ 7:
แผนการดำเนินโครงการ



ส่วนที่ 8:
ผลการศึกษาเทคโนโลยีที่
ใช้พัฒนา



ส่วนที่ 9:
สรุปผลการดำเนินงานที่
ผ่านมา




ที่มาและความสำคัญของปัญหา (MOTIVATION)

ในปัจจุบันการใช้ Data Driven ในการตัดสินใจเป็นปัจจัยสำคัญที่จะบอกได้ว่าธุรกิจนั้นจะประสบความสำเร็จหรือล้มเหลว ดังนั้นข้อมูลที่นำมาใช้จึงมีความสำคัญอย่างมาก

เนื่องจากการตัดสินใจของลูกค้า (Customer) ในหลาย ๆ อย่าง เกิดจากการใช้อารมณ์ (Emotion) มากกว่าเหตุผล (Logic) แต่อารมณ์เป็นสิ่งที่ไม่สามารถวัดค่าออกมาเป็นตัวเลขได้

ดังนั้นเราจึงจะหาวิธีการที่จะแยกแยะและบันทึกอารมณ์ของ Customer เพื่อนำไปใช้ในการตัดสินใจต่างหรือ ไปใช้ประโยชน์ในรูปแบบอื่นๆต่อไป ซึ่งเป็นที่มาของการทำโครงการการจำแนกอารมณ์จากเสียง (Speech Emotion Recognition : SER)



ส่วนที่ 1:
ที่มาและความสำคัญของปัญหา

วัตถุประสงค์ (OBJECTIVES)

เพื่อพัฒนา Application
สำหรับจำแนกอารมณ์
จากเสียงพูด



เพื่อพัฒนา Speech
Emotion Recognition
ให้เหมาะสมกับภาษา
ไทยมากขึ้น



เพื่อทำการ
Classification อารมณ์
เพื่อนำข้อมูลไปสร้าง
มูลค่าเชิงธุรกิจต่อไป



ส่วนที่ 2:
วัตถุประสงค์



ส่วนที่ 3:
ทฤษฎีที่เกี่ยวข้อง

Theoretical Background

CEPP64-01





Deep Learning

Deep Learning คือวิธีการเรียนรู้แบบอัตโนมัติด้วยการ เลียนแบบการทำงานของโครงข่ายประสาทของมนุษย์ (Neurons) โดยนำระบบโครงข่ายประสาท (Neural Network) มาซ้อนกัน หลายชั้น (Layer) และทำการเรียนรู้ข้อมูลตัวอย่าง ซึ่งข้อมูล ดังกล่าวจะถูกนำไปใช้ในการตรวจจ้บรูปแบบ (Pattern) หรือจัด หมวดหมู่ข้อมูล (Classify the Data)




Transfer Learning

Transfer Learning คือ เทคนิคที่ช่วยลดเวลาการเทรนโมเดล Deep Learning ด้วยการนำบางส่วน of โมเดลที่เทรนเรียบร้อยแล้ว กับงานที่ใกล้เคียงกัน มาใช้เป็นส่วนหนึ่งของโมเดลใหม่



Image Processing

การประมวลผลภาพ (Image Processing) หมายถึง กระบวนการจัดการ และวิเคราะห์รูปภาพให้เป็นข้อมูลในแบบดิจิทัล โดยใช้คอมพิวเตอร์การ เพื่อให้ได้ข้อมูลที่เราต้องการทั้งในเชิงคุณภาพและปริมาณ (ขนาด รูปร่าง) หลังจากนั้นเราสามารถนำข้อมูลไปวิเคราะห์ และสร้างเป็นระบบต่อไป



Web Application UU React

React.js เป็น JavaScript Front-End Frameworks ที่พัฒนาโดย Facebook ซึ่งใช้สำหรับการสร้างหน้าเว็บ และทำหน้าที่สร้างงานทางด้าน Front-end และ Back-end พร้อมด้วย action ต่างๆ ที่ทำให้เว็บของเราดู น่าสนใจ และช่วยในการตอบสนองโต้ตอบ กับผู้ใช้งานได้อย่างรวดเร็ว



ส่วนที่ 4:
งานวิจัยที่เกี่ยวข้อง

Related Works


CEPP64-01



Speech Emotion Classification Using Machine Learning Algorithms


Feature Engineering จากค่าเชิงสถิติของเสียง แล้วนำ Feature เหล่านั้นมา Train ML หลาย Algorithms เทียบกัน

Best Classifier : SMO Acc 92% DataSet : EMO-DB



Speech Emotion Recognition with Convolutional Neural Network



จำแนกอารมณ์จากเสียงโดยใช้ Convolutional Neural Network ที่มี 7 layers เป็น Convolution 6 layers และต่อด้วย Dense layer 1 layers โดยจะใช้ input ของ Model เป็น Spectrogram ที่เกิดจากนำเสียงมาแปลงให้เป็นรูปภาพ เป็นการเปลี่ยนจากปัญหา Audio problems เป็น image classification problem



Spectrogram

Pitch Tuning + Noise Adding


For positive sample only

Performance	Train Test Loss	Confusion Matrix									
Validation Acc: 84.03% Testing Accuracy: 56.875% Testing F1 Score: 56.49%		 <table><tr><th>True label \ Predicted label</th><th>male_negative</th><th>male_positive</th></tr><tr><th>male_negative</th><td>53</td><td>43</td></tr><tr><th>male_positive</th><td>26</td><td>38</td></tr></table>	True label \ Predicted label	male_negative	male_positive	male_negative	53	43	male_positive	26	38
True label \ Predicted label	male_negative	male_positive									
male_negative	53	43									
male_positive	26	38									

Real-Time Speech Emotion Recognition Using a Pre-trained Image Classification Network: Effects of Bandwidth Reduction and Companding

ใช้วิธีการ Transfer-learning โดยอาศัย Pre-train model สำหรับ Image recognition มา Finetune ในงานวิจัยนี้ใช้ Pre-train model ชื่อว่า " AlexNet" จาก ImageNet และทดสอบประสิทธิภาพของผลกระทบจาก Bandwidth reduction และ Companding

Result : Baseline Acc. 82% DataSet : EMO-DB



ขอบเขตของโครงการ (SCOPE)

มี User Interface ที่สามารถให้ผู้ใช้งาน
upload file เสียงได้

Model สามารถจำแนกอารมณ์จากเสียงที่เป็น
ภาษาไทยได้

มี API สำหรับการเรียกใช้งาน Model โดย
ไม่มี interface ได้

มีการเก็บเสียงและผลลัพธ์ลง database
เพื่อนำไปสร้างมูลค่าทางธุรกิจต่อไป



ส่วนที่ 5:

ขอบเขตของโครงการ





ส่วนที่ 6:
การพัฒนาโครงการ


Project Development

CEPP64-01






ส่วนติดต่อผู้ใช้งาน



ฐานข้อมูล




Business Process Model and Notation

แผนการดำเนินงาน (GANTT CHART)





ส่วนที่ 7:
แผนการดำเนินงาน

แผนการดำเนินงาน (GANTT CHART)



ส่วนที่ 7:
แผนการดำเนินงาน

แผนการดำเนินงาน (GANTT CHART)



ส่วนที่ 7:
แผนการดำเนินงาน

React

React เป็น JavaScript library ที่ใช้สำหรับสร้าง user interface ที่ให้เราสามารถเขียนโค้ดในการสร้าง UI ที่มีความซับซ้อนแบ่งเป็นส่วนเล็กๆออกจากกันได้ ซึ่งแต่ละส่วนสามารถแยกการทำงานออกจากกันได้อย่างอิสระ และทำให้สามารถนำชิ้นส่วน UI เหล่านั้นไปใช้ซ้ำได้อีก

FastAPI

FastAPI เป็น framework ที่ใช้สำหรับการทำ API ด้วยภาษา Python ซึ่งเป็นภาษาที่หลาย ๆ คนน่าจะคุ้นเคยดี โดยจุดเด่นของเจ้า FastAPI คือ ความรวดเร็วในการทำงาน ง่ายต่อการเรียนรู้ และมี API document อยู่ในตัวที่จะช่วยให้เราทดสอบไปพร้อมกับการพัฒนาได้อย่างทันที



ส่วนที่ 8:

ผลการศึกษาเทคโนโลยีที่ใช้พัฒนา

Python

Python เป็นภาษาการเขียนโปรแกรมระดับสูง ที่นำข้อดีของภาษาต่างๆ มารวมไว้ด้วยกัน ถูกออกแบบมาให้เรียนรู้ได้ง่าย และมีไวยากรณ์ที่ช่วยให้เขียนโค้ดสั้นกว่าภาษาอื่นๆ มีความสามารถใช้ชนิดข้อมูลแบบไดนามิก จัดการหน่วยความจำอัตโนมัติ สนับสนุนกระบวนทัศน์การเขียนโปรแกรม (Programming paradigms)

TensorFlow

TensorFlow เป็นไลบรารีสำหรับใช้พัฒนา machine learning เป็น Open source (เขียนด้วย Python) ที่พัฒนาโดยกูเกิล โดยกูเกิลได้ปล่อย TensorFlow ซึ่งเป็นไลบรารีสำหรับใช้พัฒนา machine learning ที่ใช้งานกันในกูเกิลเอง ให้กลายเป็นโปรแกรม Open source



ส่วนที่ 8:

ผลการศึกษาเทคโนโลยีที่ใช้พัฒนา

Google Colaboratory

Google Colab เป็นโฮสต์โปรแกรม Jupyter notebook บน Cloud ของ Google ชื่อเต็ม คือ Google Colaboratory โดยใช้ภาษา python3 เป็นภาษาหลักที่ใช้ในการเขียนและรันงานบน colab



ส่วนที่ 8:

ผลการศึกษาเทคโนโลยีที่ใช้พัฒนา



ส่วนที่ 9:

สรุปผลการดำเนินงานที่ ผ่านมา

Project Approach

วิธีการที่เราเลือกใช้จะเลือกทำคล้ายกับ งานวิจัยที่ 3 (Real-Time Speech Emotion Recognition Using a Pre-trained Image Classification Network: Effects of Bandwidth Reduction and Comanding)
โดยจะใช้Data Set ที่เป็นภาษาไทย และ จะทดลองกับ pre- train model หลายๆ model นำมาเปรียบเทียบ แล้วเลือก pre -train model นั้นมาใช้เป็นหลัก แล้ว Fine – tuning

การเตรียมชุดข้อมูล Speech Emotion Recognition

ชุดข้อมูลนี้ได้มีการเก็บเสียงจากทั้งหมด 5 อารมณ์ ได้แก่: Neutral (เฉยๆ), Anger (โกรธ), Happiness (ดีใจ), Sadness (เสียใจ), Frustration (หงุดหงิด) ซึ่ง Neutral, Anger, Happiness, และ Sadness

นอกจากนี้

ชุดข้อมูลนี้มีการอัดเสียงจากนักแสดงทั้งหมด 200 คน โดยใน 1 studio จะมีนักแสดงทั้งหมดสองคนรวมเป็นทั้งหมด 100 studio ซึ่งใน studio ทั้งหมด จะมีการอัดเสียงทั้งหมด 3 รูปแบบ

- 1.ห้อง studio > ห้องอัดไม่มีเสียงรบกวนและมีการบุผนังป้องกันเสียงก้อง
- 2.zoom > อัดผ่าน zoom (ไม่มีการ control ไมค์) อัดเสียงผ่านโปรแกรม Zencast
- 3.ห้องทั่วไป > มีเสียงรบกวน (เสียงแอร์, รถ) เป็นเล็กน้อย ไม่มีการบุผนังป้องกันเสียงก้อง

ซึ่งในแต่ละ studio จะมีการอัดทั้งหมด 2 แบบ script และ improvised

- Script — นักแสดงจะต้องพูดประโยคที่กำหนดให้ในแต่ละอารมณ์
- Improvised — นักแสดงจะ improvise ตามสถานการณ์และอารมณ์ที่กำหนดไว้

	ข้อมูลอารมณ์ ทั้งหมด	ข้อมูลอารมณ์ที่มีค่าความเห็นพ้องของอารมณ์ ในประโยคมากกว่าหรือเท่ากับ 0.71
ปกติ	7360	4170
โกรธ	3112	1974
สุข	4071	2974
เศร้า	2781	1595
หงุดหงิด	7861	3469
อารมณ์อื่นๆ	5	0
ไม่มีความ เห็นพ้อง	2664	0
Total	27854	14182

ตารางที่ 3: เปรียบเทียบจำนวนประโยคในแต่ละอารมณ์ก่อนและหลังคัดเลือกประโยคที่มีค่าความเห็นพ้องของอารมณ์ในประโยคมากกว่าหรือเท่ากับ 0.71



ส่วนที่ 9:

สรุปผลการดำเนินงานที่ ผ่านมา

ผลจากการทำ **Prototype- Model (Base model : EfficientB0 จาก Keras)**

จะเห็นว่า Model เกิดการ Overfit คาดว่าเนื่องจากไม่ได้ทำการ Early Stoppage ไว้ในขณะที่ Train model

เป็นปัญหาที่พบได้ทั่วไปใน Deep Learning

หมายเหตุ : Model นี้เป็นเพียง Prototype ไม่ได้นำ Model นี้มา Deploy จริงๆ ในส่วนของ Model ที่จะใช้ในการ Deploy จะถูกพัฒนาขึ้นต่อไปในภาคการศึกษาหน้าในวิชา Project I และ Project II

Data set	Loss	Accuracy
Train set	0.025	98.79
Test set	2.4	53.15

ขอบคุณ

CEPP64-01

Classifying Emotion of Thai-Human Voice by Using Deep Learning

สมาชิก

62010558

นาย ปิยพัทธ์ บุญแกม

62010794

นาย วรณิพิฐ ชัยพินิจนรชาติ

อาจารย์ที่ปรึกษา

รศ.ดร.เกียรติกุล เจียรนัยธนะกิจ